DressMe — Module M7 « Catalogue local »

Rapport technique · BO6 Marché tunisien · ESPRIT 2026 Collecte des données (scraping), nettoyage, moteur de recherche de vêtements dans les boutiques tunisiennes, et évaluation.

Mis à jour le 22/10/2026 : LLM Qwen 2.5 7B (§5.13, §6.6). Le 16/10/2026 : 43 boutiques, 6 375 produits. Première version le 14/10/2026 (15 boutiques, 2 471 produits).

Sommaire

1. Contexte et objectif
2. Vue d'ensemble
3. Collecte des données : le scraping
4. Nettoyage des données
5. Le module M7
6. Évaluation
7. Comment tester le module
8. Limites et pistes d'amélioration
9. Annexe : fichiers du module

---

1. Contexte et objectif

DressMe est un assistant de mode personnel. Le module **M7 « Catalogue local »** répond à un besoin précis du marché tunisien : une utilisatrice cherche par exemple *des baskets blanches à Tunis pour un budget de 80 TND*. Aujourd'hui elle doit parcourir des dizaines de pages Instagram et de sites. M7 lui propose directement des articles de boutiques tunisiennes adaptés à sa demande, à son budget et à sa ville, qu'elle écrive en français, en anglais, en darija ou en arabe.

Exemple de résultat obtenu par le module :

> **Manuella · Tunis · Basket à plateforme femme · 69,3 TND · lien vers la fiche produit**

Place dans le projet. D'après le document de répartition des tâches (*Task Split*), M7 est un **module partagé** : il est construit une seule fois par BO6 et appelé par d'autres BO (BO1, BO2, BO3, BO5, BO7, BO8, BO9). Il doit donc exposer une API stable. Le document d'architecture (*DressMe_MultiAgent_Pipeline.pdf*, section 7 « Local shop agent ») fixe :

Élément	Exigence de l'architecture	Ce qui a été réalisé
Base de connaissances	CSV/JSON de boutiques et de pièces, sans scraping en direct	CSV nettoyé de 6 375 produits (43 boutiques) + index d'images, dans `ml/data/shops/`
Recherche	Embeddings + BM25 (hybride)	FashionCLIP (image + texte) + BM25

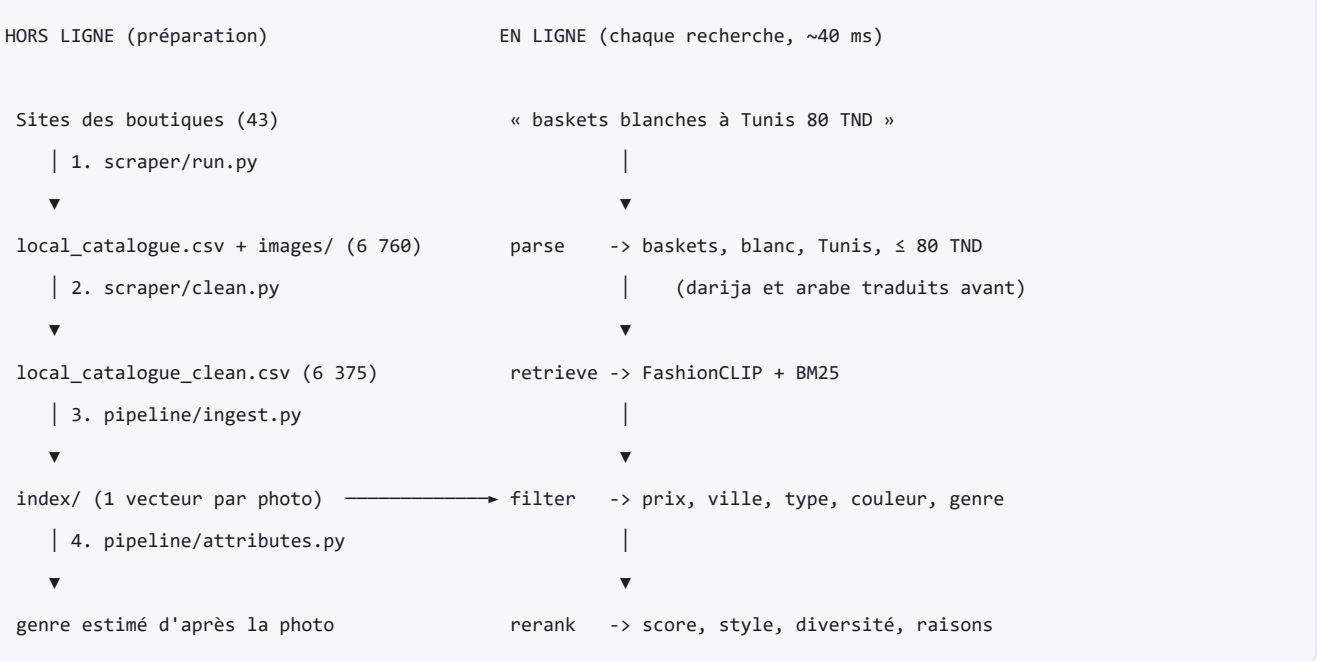
Élément	Exigence de l'architecture	Ce qui a été réalisé
Filtres	Prix (TND), ville, catégorie, style	Prix, ville/gouvernorat, catégorie, **couleur**, **genre**, stock, vecteur de style
Intégration	Outil appelable par l'orchestrateur (LangGraph)	Outil `localshop` + API REST `/m07/*` + écran BO6 Flutter
Entrée / sortie	`query, gap, style_vector` → `shop, area, item, price_tnd, match`	Mêmes champs, enrichis (liens, photo, genre, raisons, pagination)

La demande complémentaire était d'utiliser **FashionCLIP en local en Python**, ce qui a été fait (§5.2). Ce choix a ensuite été comparé à deux modèles plus récents sur notre catalogue (§5.12), et le module a été **évalué** sur 72 requêtes écrites à la main (§6).

---

2. Vue d'ensemble

Le travail se fait en deux temps : une préparation des données **hors ligne** (à relancer de temps en temps pour mettre à jour prix et stocks), puis une recherche **en ligne** très rapide.



Toutes les données (CSV, photos, index, rapports) sont dans `ml/data/shops/` et sont **versionnées dans git** sur la branche `BO6/local_catalogue` (≈ 340 Mo, dont 327 Mo de photos), pour que l'équipe les récupère avec un simple `git pull`. Le README du projet prévoit DVC pour les données : la bascule vers DVC ou Git LFS reste possible si le dépôt devient trop lourd (§8).

2.1 Input → modèle → output

Chaque étape reçoit une entrée (*input*), la transforme avec un modèle ou une méthode, et produit une sortie (*output*) qui devient l'entrée de l'étape suivante.

Étape	Input	Modèle / méthode	Output
1. Scraping	Données d'une boutique (ex. JSON Shopify de Manuella)	Adaptateur de plateforme + règles de normalisation	1 ligne CSV brute + 1 photo JPEG
2. Nettoyage	Ligne brute	Règles, empreinte d'image *dHash*, vérification HTTP	1 ligne propre (28 colonnes)
3. Indexation	Photo JPEG (800 px)	**FashionCLIP — encodeur d'image** (réseau de neurones pré-entraîné)	Vecteur de 512 nombres
4. Genre d'après la photo	Vecteur de la photo	**FashionCLIP zero-shot** (« women's … » contre « men's … »)	`gender` + `gender_source = photo`, si le modèle est assez sûr
5. Compréhension	Phrase de l'utilisatrice (FR, EN, darija, arabe)	Lexique darija + règles `parse.py`	Critères + phrase en anglais
6. Encodage de la requête	Phrase en anglais	**FashionCLIP — encodeur de texte**	Vecteur de 512 nombres
7. Recherche	Vecteur de la requête + 6 375 vecteurs de photos + mots	Similarité cosinus + BM25	2 scores par produit
8. Filtres et classement	Scores + critères	Filtres, somme pondérée, diversité (MMR)	Les k meilleurs produits, avec `match` et raisons

Seules les étapes 3, 4 et 6 utilisent un modèle d'intelligence artificielle (FashionCLIP). Les autres sont des règles et des calculs : elles sont rapides, gratuites et explicables.

Exemple réel de bout en bout

Le produit suivi est la **« Basket à plateforme femme » de Manuella** ; la requête est celle du sujet.



Hors ligne — le produit entre dans le catalogue

Étape 1 · Scraping. *Input* : la fiche JSON publique de la boutique Shopify (extrait).


```
{"title": "Basket à plateforme femme", "vendor": "Manuella",
 "options": ["couleur", "Pointure"],
 "variants": [{"option1": "Blanc", "option2": "41", "price": "69.300"},
              {"option1": "Blanc", "option2": "40", "price": "69.300"}, "..."]}
```


Output : une ligne brute du fichier `local_catalogue.csv` (et la photo `images/2b7db627f328cf6a.jpg`).

```
Manuella | Basket à plateforme femme | Sneakers | Blanc | 41, 40, 39, 38, 37, 36 | 69.3 TND
         | Tunis | true
```

Étape 2 · Nettoyage. *Input* : la ligne brute. *Output* : la ligne propre (extrait). Le genre est lu dans le nom (« femme »).


```
{"product_id": "prd_2b7db627f3", "category": "shoes", "subcategory": "sneakers",
 "label_fr": "Baskets", "color": "white", "color_fr": "Blanc", "color_hex": "#FFFFFF",
 "gender": "women", "gender_source": "text", "size": "36, 37, 38, 39, 40, 41",
 "size_type": "numeric", "price_tnd": 69.3, "currency": "TND", "city": "Tunis",
 "governorate": "Tunis", "product_url_status": "ok", "missing_fields": ""}
```

Étape 3 · Indexation (FashionCLIP). *Input* : la photo ci-dessus. *Output* : un vecteur de 512 nombres qui décrit son contenu visuel.

```
[-0.015, 0.046, -0.003, -0.019, -0.045, … 507 autres nombres]
```

En ligne — la recherche de l'utilisatrice

Input de l'API (`POST /m07/search`) :

```
{"query": "baskets blanches à Tunis pour un budget de 80 TND", "k": 3}
```

Étape 5 · Compréhension. *Output* :

```
{"category": "shoes", "subcategory": "sneakers", "color": "white", "max_price_tnd": 80.0,
 "city": "Tunis", "governorate": "Tunis", "terms": ["basket", "blanche"],
 "prompt_en": "a photo of white sneakers", "translated": null, "corrected": null}
```

Étape 6 · Encodage de la requête (FashionCLIP). *Input* : `"a photo of white sneakers"` . *Output* : `[-0.047, 0.004, -0.097, -0.006, 0.003, … 507 autres nombres]` .

Étape 7 · Recherche. Pour notre basket : - similarité cosinus entre le vecteur de la requête et celui de la photo : **0,289** (le meilleur score du catalogue est 0,342) ; - score BM25 des mots « basket » et « blanche » dans sa fiche : **3,99**.

Étape 8 · Filtres et classement. - Filtres (baskets, prix ≤ 80 TND, gouvernorat de Tunis, **blanc**, en stock) : **6 375 → 1 produit**. Sans le filtre de couleur, 28 baskets de 11 couleurs différentes passeraient (§5.5). - Composantes du score de notre basket : - visuel = (0,289 − 0,15) / (0,33 − 0,15) = **0,772** ; - texte = **1,0** (c'est le meilleur candidat) ; - attributs (baskets + blanc) = **1,0** ; - pas de genre ni de vecteur de style dans cette requête. - `match` = (0,45 × 0,772 + 0,20 × 1,0 + 0,20 × 1,0) / (0,45 + 0,20 + 0,20) = **0,880**.

Output de l'API (extrait) :

```
{"shop": "Manuella", "area": "Tunis", "item": "Basket à plateforme femme", "price_tnd": 69.3,
 "match": 0.88, "product_id": "prd_2b7db627f3", "category": "shoes", "subcategory": "sneakers",
 "color": "white", "gender": "women", "size": "36, 37, 38, 39, 40, 41", "available": true,
 "image_path": "images/2b7db627f328cf6a.jpg",
 "product_url": "https://manuella.com.tn/products/basket-a-plateforme-femme",
 "reasons": ["Baskets", "Couleur : blanc", "69.3 TND (budget 80 TND)", "Boutique à Tunis",
             "Ressemble visuellement à la demande", "Marque tunisienne"]}
```

---

3. Collecte des données : le scraping

3.1 Choix des sources

La collecte s'est faite en **deux campagnes**.

Campagne 1 (14/10/2026) : 37 sources, 15 boutiques retenues. Le point de départ était une liste de 28 sources : 5 places de marché ou annuaires (Ad. Mall, Moudda, Lofa, Hawwini, Boutique.tn), 7 enseignes de prêt-à-porter (VOG, HA, Apparel, Celina Fashion, MAGIC, UNJA, Corella) et 16 boutiques citées dans l'annuaire Hawwini. 9 sources ont été ajoutées pour les bijoux, accessoires et chaussures (Strass Accessoires, HK-STORE, GAŸA, The Queen Accessories, SKILA, Joliesse, Azar Shoes, Chaussures Pitillos, Shoes Center). Les adresses des sites ont été retrouvées sur les fiches « retailer » de Hawwini puis par recherche web. *Pourquoi :* deviner les domaines aurait donné de faux sites.

Campagne 2 (15/10/2026) : recherche ville par ville, 28 boutiques ajoutées. Objectif : couvrir plus de villes et les catégories pauvres (tenues traditionnelles, mode homme, maillots de bain, lingerie, bijoux). Méthode : 1. recherches web par ville (Tunis, Ariana, Ben Arous, Sousse, Monastir, Mahdia, Sfax, Nabeul, Bizerte, Kairouan, Gabès, Djerba, Gafsa) et par catégorie (chaussures en cuir, sacs, bijoux, jebba et caftan, hijab et burkini, lingerie, homme, couffins) ; listes de marques tunisiennes de *L'Instant M* et *Marhba* ; 2. **sonde automatique** de chaque candidate : site joignable ? plateforme (Shopify, WooCommerce, PrestaShop, JSON-LD) ? prix en TND ? `robots.txt` autorise-t-il la collecte ? 3. exclusion des enseignes étrangères (Celio, Kiabi), des revendeurs de marques étrangères (Le Sportif, Super Sport, DREST), de la seconde main (Sou9 Finds) et des vêtements importés (New Collection, Mahdia).

Sources écartées, avec la raison (la liste est aussi dans `scraper/shops.py`, `SKIPPED`) :

Source	Raison
ZEN, Souk El Kahina	Leur `robots.txt` **interdit la collecte** : ce choix est respecté
Mabrouk (Tunis, Nabeul, Sousse)	Flux WooCommerce lisible, mais chaque photo tourne en boucle de redirections puis le site ne répond plus ; à retenter
HKEYA (Ariana), Bassamet, HK-Store	Répondent « 429 Too Many Requests » même avec 3 s entre deux requêtes
Kastelo, El Khomssa	Sites sur mesure, fiches produit absentes du sitemap : analyseur HTML dédié nécessaire
Barsha, Rosace, Fedia Fashion	Sites entièrement en JavaScript, ou JSON-LD sans nom ni photo
Diamelle	Joaillerie de luxe et montres d'occasion de marques étrangères (Rolex…)
JENNAH Boutique, Ayada Boutique	Boutiques **françaises** (prix en euros)
Scarpa Store, Sneakers Tunisie, Sneakers Outlet, Le Sportif, Super Sport, DREST	Revendent **surtout des marques étrangères**
Celio, Kiabi, Chaussures Pitillos	Enseignes ou marques étrangères
Lofa	Catalogue de démonstration (photos de banque d'images)
Celina Fashion, SKILA	Sites vitrines sans catalogue ni prix
Dabchy, Sou9 Finds	Seconde main
Hawwini	Comparateur de prix : utilisé seulement pour trouver les adresses
GAŸA, The Queen Accessories, Azar Shoes	Aucun site trouvé
Modeco, Fripup, Spadri, Unill (Gafsa), Lascarfa (Sousse), Lunja, Angel (Mahdia), 100 % Tounsi	Site injoignable, en panne ou certificat invalide
Ad. Mall, boutique.tn, D'Stock, Pink and Grey, Folla Création (Nabeul)	Pas de données structurées : analyseur HTML dédié nécessaire

Résultat : 43 boutiques dans le catalogue final.

3.2 Détection de la plateforme de chaque site

Avant d'écrire le moindre code de scraping, chaque site a été analysé : quelle plateforme e-commerce utilise-t-il ? On examine la page d'accueil (balise `generator`, signatures comme `cdn.shopify.com` ou `wp-content`) et on teste les adresses de données connues de chaque plateforme. Pour la campagne 2, cette analyse a été automatisée (sonde de 48 sites).

Plateforme	Boutiques	Méthode de récupération
Shopify	Moudda, NOON, Manuella, Kontakt, SeaSide, Emraa, Gaya, Iley'com	Flux public `/products.json`
WooCommerce	VOG, Corella, Apparel, KAI Signature, Wivine, Lunar, AD Makeba, Opierre, Hraier, Caprice, Exclusive, Intimate, Lingerie.tn, Patrinova, Sougui	*Store API* publique `?rest_route=/wc/store/v1/products`
PrestaShop 1.7+	Exist, FEModest, Shoes Mall, Strass, Joliesse, Chill&Lit, Ultima, Baletto, Carolie, Cravate, CityMode, Hijabella, Lyséa, Ms. Marion, Maison ARA	Pages catégories demandées en JSON (en-tête `X-Requested-With`), tailles lues sur la fiche produit
PrestaShop 1.6	LYOUM	Lecture des « cartes produit » HTML (thème personnalisé)
Pages avec JSON-LD	MAGIC, UNJA, GET	Données `schema.org/Product` de chaque fiche (listées par le sitemap ou les pages catégories)
API privée	HA	API JSON utilisée par leur propre site

Pourquoi cette approche : les plateformes exposent déjà leurs produits sous forme de **données structurées** (JSON). C'est beaucoup plus fiable que d'extraire du texte depuis le HTML : prix, devise, variantes, stock et photos arrivent déjà séparés. On a écrit **un adaptateur par plateforme** (`scraper/sources.py`) plutôt qu'un code par site : les 28 boutiques de la campagne 2 ont été ajoutées en une ligne de configuration chacune.

Correction de l'adaptateur PrestaShop. Baletto nomme ses produits par modèle (« Cinzia Noir Daim ») : seule la catégorie du site dit qu'il s'agit de sandales. L'adaptateur visitait d'abord la catégorie générale « femme » et ignorait ensuite le même produit dans « sandales ». Il **ajoute désormais** chaque catégorie rencontrée : Baletto passe de **2 à 162 produits**.

3.3 Un scraping respectueux des sites

Règle	Mise en œuvre	Raison
Respect du `robots.txt`	Chaque URL est vérifiée avant d'être demandée ; ZEN et Souk El Kahina, qui l'interdisent, ne sont pas collectés	Les sites indiquent ce qu'ils autorisent
Pas de surcharge	0,5 s minimum entre deux requêtes vers un même site (1 s pour la vérification des URL) ; un site qui répond 429 avec 3 s d'écart est abandonné	Ne pas gêner les boutiques
Robot identifiable	User-Agent `DressMeCatalogueBot/0.1 (student project, ESPRIT)`	Transparence
Erreurs temporaires	Jusqu'à 6 nouvelles tentatives avec attente croissante (429, 5xx)	Robustesse
Pas de cookies	Client « sans état »	Voir ci-dessous

Problème rencontré : erreurs 429 sur Shopify. Shopify bloque le flux `/products.json` **dès que ses cookies de session sont présents** (posés lors de la lecture du `robots.txt`). Solution : un client qui refuse tous les cookies, dont les sites n'ont pas besoin pour afficher un catalogue public.

3.4 Normalisation pendant la collecte

Chaque boutique décrit ses produits à sa façon. Pour obtenir un catalogue homogène, on applique des règles par mots-clés (`scraper/normalize.py`) :

- **Catégorie** à partir du nom du produit, puis de la catégorie de la boutique. Les règles couvrent le français, l'anglais, les mots tunisiens et l'arabe : *dengri* (jean), *pul* (pull), *joking* (jogging), *jebba*, *jelbeb*, *tabdila*, *جلباب*, *كسوة*… L'**ordre des règles compte** : « veste en jean » est une veste, « short basket » un short (basket-ball), « haut de gamme » n'est **pas** un haut.
- **Orthographes des boutiques** : « Colier », « Gillet », « Boucles d’oreilles » avec une apostrophe typographique (’) sont reconnus.
- **Couleur principale** : couleur citée dans le nom, sinon la première variante de couleur. Des codes comme `T00849-NOIRDEL` sont aussi reconnus.
- **Tailles** : seulement les tailles **en stock** quand la boutique donne le stock par taille.
- **Prix** : seuls les prix **en TND** sont conservés (la devise est vérifiée pour chaque plateforme).
- **Ville** : vérifiée sur le site ou dans une source (page « nos magasins », presse), par exemple VOG → Bizerte, LYOUM → La Marsa, Carolie et SeaSide → Sfax, Ultima → Nabeul, Lyséa → Tunis, GET → Tunis, Sfax, Sousse, Gabès. **Laissée vide** quand aucune source ne donne d'adresse.

3.5 Filtres appliqués pendant la collecte

Filtre	Exemples retirés	Raison
Hors mode	Livres, chapelets, valises, coussins ; **décoration, meubles et nourriture** des places de marché (vases, miroirs, consoles, tabourets, gâteaux, sculptures…)	Ce ne sont pas des vêtements
Enfants / bébés	« Sandale fillette », « Baskets Garçonnet »	DressMe s'adresse à la garde-robe d'adultes
Marques étrangères	Nike, Adidas, UGG, Moncler… ; montres et bijoux (Bigotti, Rolex, Swarovski…) ; lingerie (Simone Pérèle, Triumph…)	Objectif BO6 : promouvoir les marques et boutiques **locales**
Produit sans prix ou sans photo	Kontakt publie 237 produits sur 250 sans photo	Un produit sans photo ne peut pas être affiché ni encodé

Le filtre hors mode a **deux niveaux**. Les mots sans ambiguïté (« vase », « console », « gâteau ») excluent toujours. Les mots ambigus (« décoratif », « corbeille », « miroir », « porte-clés », « panier ») n'excluent que si le nom ne désigne **aucune pièce** : « Sac avec charm décoratif », « Soutien-gorge corbeille » et « Ceinture et porte-clés » restent ; « Cœur décoratif » et « Miroir soleil en rotin » partent. Une première version trop stricte retirait à tort 28 vrais articles (sacs « avec charm décoratif », soutiens-gorge « corbeille », bottines « à boucle décorative »…) : ils ont été retrouvés en comparant les produits retirés boutique par boutique, et un test les protège désormais.

Places de marché artisanales (Iley'com, Hraier, Patrinova, Sougui). Elles vendent aussi de la décoration et des produits alimentaires, classés sous des catégories trompeuses (« Haut-parleur » rangé avec les hauts). Pour elles (`name_only` dans `shops.py`), un produit n'est gardé que si **son nom** désigne un vêtement ou un accessoire.

Équilibre du catalogue. On garde au maximum **300 produits par boutique**, choisis à tour de rôle dans chaque catégorie, et le filtre des marques étrangères est appliqué **avant** ce quota.

3.6 Photos des produits

Une photo est téléchargée pour chaque produit dans `ml/data/shops/images/`, convertie en JPEG de 800 px maximum (**6 760 photos, 327 Mo, environ 45 Ko chacune**). Le nom du fichier est dérivé de l'URL du produit : il ne change pas d'une mise à jour à l'autre, et une photo déjà présente n'est pas retéléchargée. *Pourquoi :* FashionCLIP a besoin des images en local, et l'application les affiche sans dépendre des sites des boutiques (route `/m07/images/…`).

3.7 Résultat du scraping

Campagne 1 (15 boutiques) :

Boutique	Produits lus	Retenus	Principales exclusions
Moudda	1 250	300	272 marques étrangères, 71 enfants
Manuella	700	300	73 enfants
VOG	1 200	300	—
Exist	1 163	300	12 hors mode
HA	791	300	29 enfants
Strass Accessoires	825	300	30 hors mode, 9 enfants
Joliesse	357	300	18 hors mode (valises), 20 enfants
MAGIC, NOON, LYOUM, Apparel, Corella, UNJA, FEModest, Shoes Mall	581	433	livres, maison, enfants

Campagne 2 (28 boutiques) :

Boutique	Produits lus	Retenus	Principales exclusions
CityMode	1 200	300	**524 marques étrangères**, 88 enfants
Iley'com	1 250	300	505 hors mode (décoration)
Chill&Lit	1 246	300	237 hors mode, 161 enfants
Hraier	1 200	300	384 hors mode (pâtisseries…), 241 sans prix
Kontakt	1 250	300	254 enfants (puis 221 sans photo)
Gaya	853	300	260 hors mode, 14 marques étrangères
SeaSide, Exclusive, Intimate, Cravate	1 605	1 199	—
AD Makeba, GET, Baletto, Ms. Marion, Maison ARA	923	900	quelques hors mode

Boutique	Produits lus	Retenus	Principales exclusions
Caprice, Lyséa, Carolie, Lingerie.tn, Patrinova, Opierre, Sougui, Lunar, Wivine, Ultima, Hijabella, KAI, Emraa	741	539	Sougui : 103 hors mode sur 129
Total (2 campagnes)		**6 760 avec photo**	256 produits sans photo utilisable

3.8 Ajouter ou mettre à jour des boutiques

L'option `--merge` scrape seulement les boutiques demandées et garde les autres telles quelles, avec leurs photos :

```
python -m modules.m07_local_catalogue.scraper.run --shops baletto --merge
# site sensible au débit : 3 s entre deux requêtes
python -m modules.m07_local_catalogue.scraper.run --shops hkeya --merge --delay 3
```

Pourquoi : corriger Baletto n'a demandé que cette boutique (environ 5 minutes), au lieu de relancer les 42 autres.

---

4. Nettoyage des données

Le script `scraper/clean.py` transforme `local_catalogue.csv` (6 760 produits) en `local_catalogue_clean.csv` (**6 375 produits**). Chaque étape est comptée dans `ml/data/shops/cleaning_report.md`. Les règles de catégories sont réappliquées au nom de chaque produit : une correction de règle profite au catalogue sans refaire le scraping.

Étape	Produits retirés
Doublons (63 dans une même boutique, 32 entre boutiques)	95
Hors mode (décoration, meubles, nourriture, porte-clés, valises…)	111
Places de marché : nom qui ne désigne aucune pièce	109
Marques étrangères (noms de modèles vendus sans la marque)	58
Enfants	6
Fiches mortes (404 ou redirection vers l'accueil)	6
Total	**385**

4.1 Prix convertis en nombres et vérifiés en TND

Tous les prix sont des nombres décimaux, strictement positifs, en TND (garanti à la source par chaque adaptateur). Les prix très éloignés de la médiane de leur sous-catégorie (moins d'un cinquième ou plus de cinq fois) sont **signalés** dans `quality_flags` (51 très bas, 122 très hauts) mais **jamais modifiés**. *Pourquoi :* un prix inhabituel n'est pas forcément faux (une épingle de hijab à 0,5 TND est réelle). En revanche, deux sacs Hraier affichés à **14 900 TND** sont très probablement une erreur de saisie de la boutique : ils restent signalés, et c'est un point à vérifier à la main (§8).

4.2 Dernier contrôle « local uniquement »

Le nettoyage repasse le filtre des marques étrangères avec une liste enrichie de noms de modèles vendus sans la marque dans le titre (« AIR FORCE 1 '07 », « On Cloudtilt »…) : **58 produits retirés**.

4.3 Nomenclature commune des catégories

Les catégories sont alignées sur le **contrat de données partagé** du projet (`GarmentCategory` : `top` , `bottom` , `dress` , `outerwear` , `shoes` , `accessory` , `traditional`), avec une **sous-catégorie** précise et un **libellé français** :

Avant (texte des boutiques)	`category`	`subcategory`	`label_fr`
sneakers, baskets, basket, *sbadri*	shoes	sneakers	Baskets
chaussures, mocassins, derbies	shoes	shoes	Chaussures
costume, tailleur, smoking	dress	suit	Costumes
collier, colier, pendentif, chaîne	accessory	necklace	Colliers
bracelet, gourmette, manchette	accessory	bracelet	Bracelets
bague, alliance	accessory	ring	Bagues
boucles / puces d'oreilles	accessory	earrings	Boucles d'oreilles
jebba, kaftan, tabdila, جلباب	traditional	traditional	Tenues traditionnelles

Pourquoi : le module Vision (M1) classe la garde-robe avec ces mêmes catégories : M7 et M1 « parlent la même langue ». Répartition finale : accessoires 1 706, chaussures 1 655, hauts 1 400, robes / ensembles / costumes / maillots 695, bas 598, vestes et manteaux 242, tenues traditionnelles 79.

4.4 Couleurs, tailles, villes et genre uniformisés

- **Couleurs** : un code anglais (`white` , `navy` …) identique à celui du module Vision, plus le nom français (`Blanc`) et un code hexadécimal (`#FFFFFF`).
- **Tailles** : une seule notation, triée (`2XL` → `XXL` , `ST` → `Taille unique`), et une colonne `size_type` (`letter` , `numeric` , `one_size` , `bra` …).
- **Villes** : nom officiel et **gouvernorat** (`La Marsa` → `Tunis`). *Pourquoi :* une utilisatrice qui cherche « à Tunis » doit aussi voir les boutiques de La Marsa.
- **Genre** (nouveau) : `women` , `men` ou `unisex` quand le nom ou l'URL le dit (« Basket femme », `/collections/homme`), avec `gender_source = text` . Si les deux genres sont cités, ou aucun, le genre reste vide ; l'étape 4 (§5.7) le complète ensuite d'après la photo.

4.5 Suppression des doublons

Deux produits sont des doublons s'ils ont **le même nom, le même prix et une photo quasi identique**, comparée avec une **empreinte perceptuelle** (*dHash* sur 64 bits). Comparer seulement le nom et le prix aurait été une erreur : « Basket Homme » à 59,5 TND existe en 4 couleurs avec 4 photos différentes. **95 doublons retirés** (63 dans une même boutique, 32 entre deux boutiques).

4.6 Vérification des URL

Chaque URL de fiche produit et de photo a été vérifiée par une requête HTTP (**13 202 URL**). - Une fiche qui renvoie 404/410, ou qui redirige vers la page d'accueil, est **morte** : le produit est retiré (**6**). - Les autres échecs sont **signalés** sans retirer le produit (38 fiches encore en « 429 »). - Les résultats sont mis en cache (`url_checks.json`) et **réutilisés pendant 7 jours**. *Pourquoi :* le premier contrôle a pris environ 55 minutes ; une relance le lendemain (nouvelles règles) n'a revérifié que les 302 URL en échec, en quelques minutes, sans resolliciter les 43 boutiques.

4.7 Informations manquantes marquées, jamais inventées

Une valeur absente reste **vide** et le nom du champ est listé dans `missing_fields` .

Champ	Renseigné	Pourquoi il manque parfois
Couleur	85,5 %	Nom sans couleur et pas de variante de couleur (bijoux, accessoires…)
Taille	64,5 %	Accessoires et bijoux, ou boutique qui ne publie pas les tailles
Ville	43,1 %	Boutiques en ligne sans adresse publiée (3 625 produits)
Genre	92,0 %	Écrit dans le nom (1 834) ou estimé d'après la photo (4 033) ; 508 inconnus

Pourquoi : une couleur ou une ville inventée pourrait envoyer l'utilisatrice dans une boutique qui n'a pas l'article. Le moteur en tient compte (§5.5) et le dit (« Couleur non précisée par la boutique », « Genre non précisé par la boutique »).

4.8 Identifiants stables

Chaque produit reçoit un identifiant `prd_` + empreinte de son URL (par exemple `prd_2b7db627f3`). *Pourquoi :* d'autres modules (favoris, liens partenaires M13, partage M10) ont besoin d'une référence durable, et l'index FashionCLIP réutilise les vecteurs déjà calculés grâce à cet identifiant.

4.9 Le catalogue final

Indicateur	Valeur
Produits	**6 375** (2 471 le 14/10)
Boutiques	**43** (15 le 14/10)
Marques tunisiennes / boutiques locales multimarques	3 627 / 2 748
En stock	5 393
Prix médian	78 TND
Genre	4 218 femme, 1 641 homme, 8 mixte, 508 inconnu
Sélection	771 sacs, 606 pièces de lingerie, 416 sandales, 403 baskets, 291 chemises, 253 robes, 243 colliers, 174 escarpins, 111 bagues, 79 tenues traditionnelles, 40 robes noires (contre 10)

Produits par gouvernorat (une chaîne compte dans chaque ville) : Tunis 2 027, Sfax 1 450, Sousse 879, Nabeul 695, Bizerte 685, Ariana 631, Ben Arous 590, Monastir 590, Gabès 495, Médenine 296, Béja 90, Le Kef 90 ; 3 625 produits de boutiques en ligne sans ville.

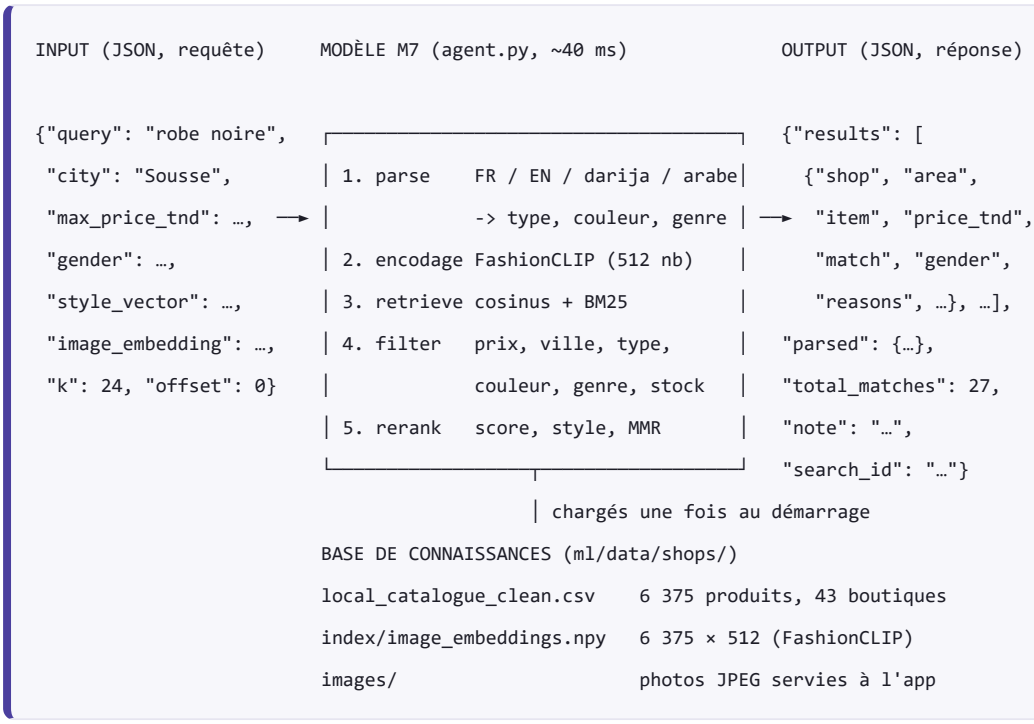
Boutique	Produits	Boutique	Produits	Boutique	Produits
Cravate	300	Hraier	220	Lyséa	79
Exclusive	300	GET	199	Kontakt	76
Manuella	300	Iley'com	181	Carolie	65
Intimate	299	Baletto	162	Lingerie.tn	49
SeaSide	299	Ms. Marion	151	Corella Store	48
HA	299	Maison ARA	112	Opierre	36
VOG	299	Patrinova	98	UNJA	36
Joliesse	296	MAGIC	90	FEModest	27
Strass Accessoires	294	NOON Clothing	90	Lunar	24
Exist	294	Caprice Lingerie	83	Wivine	23
Gaya	293	LYOUM	80	Apparel, Sougui	18
Chill&Lit	282			Ultima Boutique	15
Moudda	280			Hijabella	14
CityMode	274			KAI Signature	11
AD Makeba	247			Shoes Mall	9
				Emraa (ex-luma)	5

5. Le module M7

5.0 Input → modèle → output de M7

Le §2.1 suit tout le parcours, du scraping à la recherche. Ici on ne regarde que **le module M7 lui-même**, c'est-à-dire ce qui se passe à chaque appel de `POST /m07/search` (ou de l'outil `localshop`).

Deux formats, deux rôles. L'**entrée et la sortie** sont en **JSON** : c'est le format des messages de l'API, ce que l'application, l'assistant (M8) ou un autre module envoie à M7 et reçoit en retour. Les **données** dans lesquelles M7 cherche sont la **base de connaissances** : le CSV nettoyé, l'index FashionCLIP et les photos. Elles sont lues **une seule fois**, au démarrage de l'API (`Catalogue.load`), puis gardées en mémoire ; le CSV n'est jamais relu pendant une recherche, d'où les ~40 ms par requête.



Partie	Ce qu'elle reçoit	Ce qu'elle fait	Ce qu'elle produit
Input	Une phrase (`query`), un manque de la garde-robe (`gap`), des filtres explicites (`city` , `max_price_tnd` , `subcategory` , `color` , `gender` …), éventuellement un vecteur de style (M5) ou d'image (M1), la page (`k` , `offset`)	Validation Pydantic (`LocalShopInput`) : au moins un critère de recherche	Une demande valide, sinon erreur 422
Modèle	La demande + la base de connaissances en mémoire	Règles (compréhension, filtres) + **FashionCLIP** (seule partie apprise) + BM25 + score pondéré	Les produits classés
Output	La page demandée	`LocalShopOutput`	`results` , `parsed` (ce qui a été compris, y compris la traduction darija), `total_matches` , `note` , `search_id`

Exemples réels (catalogue du 16/10, 43 boutiques)

Chaque ligne est une vraie réponse de l'API, avec `k = 3` (les 3 premiers résultats).

Input envoyé à M7	Ce que M7 a compris (`parsed`)	Output (`total_matches` puis résultats)
`{"query": "baskets blanches à Tunis pour un budget de 80 TND"}`	baskets · blanc · Tunis · ≤ 80 TND	**1** — Manuella · Tunis · Basket à plateforme femme · 69,3 TND (0,880)

Input envoyé à M7	Ce que M7 a compris (`parsed`)	Output (`total_matches` puis résultats)
`{"query": "robe noire", "city": "Sousse"}`	robe · noir · Sousse	**27** — Ms. Marion · Robe longue en maille noir · 92 TND (0,865) ; Maison ARA · Robe Bretelle Gaga · 119 TND (0,861) ; Hraier · Robe jerbia haiek laine noir · 225 TND (0,821). *note* : « Rien trouvé à Sousse : résultats d'autres villes ou de boutiques en ligne. »
`{"query": "sbadri kahla a9al men 150 alf"}` (darija)	`translated` = « baskets noir moins de 150 alf » → baskets · noir · ≤ 150 TND	**47** — Exist · Baskets · 119,99 TND (1,0) ; HA · Basket Femme · 129,99 TND (0,963) ; Carolie · Sfax · Baskets Chics · 89,9 TND (0,956)
`{"query": "سروال رجالي"}` (arabe)	« pantalon homme » → pantalon · homme	**83** — NOON · Pantalon habillé fuselé · 39,9 TND (0,941) ; GET · Pantalon jogger · 64,95 TND (0,926) ; GET · Pantalon jogg avec zip · 71,92 TND (0,902)
`{"query": "chemise homme blanche"}`	chemise · blanc · homme	**25** — Cravate · Chemise col ouvert popeline · 89 TND (0,968) ; Chemise popeline col mao · 59,43 TND (0,954) ; Chemise col mao aspect lin · 55,3 TND (0,906)
`{"query": "chemize blanche"}` (faute)	`corrected` = « chemise blanche »	**42** — Cravate · 89 TND (0,951) ; Ms. Marion · Dalya Shirt · 34,5 TND (0,929) ; Cravate · 55,3 TND (0,896)
`{"subcategory": "bag", "color": "camel", "max_price_tnd": 150}` (champs seuls)	sac · camel · ≤ 150 TND	**19** — Carolie · Sfax · Sac à bandoulière en vrai cuir · 79,5 TND (1,0) ; Hraier · Sac cabas crochet caramel · 99 TND (1,0) ; SeaSide · Sfax · Sac Medium Camel · 119,9 TND (0,984)
`{"query": "zorglub"}` (mot inconnu)	rien	**0** — *note* : « Je n'ai trouvé aucun article correspondant à « zorglub » dans les boutiques locales. »
`{"query": "robe", "k": 24, "offset": 24}` (page 2)	robe	**193** — les 24 robes suivantes, sans répéter la page 1
`{"city": "Tunis"}` (rien à chercher)	—	Erreur **422** : l'entrée est refusée avant le modèle

À retenir. - Une **couleur demandée est stricte** : « robe noire » ne montre que des robes noires. Si la couleur n'existe nulle part, M7 le dit dans `note` et montre les autres couleurs (§5.5). - Le champ `area` donne **la ville du magasin qui correspond au filtre** ; pour une chaîne sans filtre, « Chaîne présente dans 4 villes (Tunis, Sfax, Sousse…) ». - Le `match` (0 à 1) et les `reasons` sont calculés uniquement à partir des données et des scores.

5.1 Architecture et contrat

Le module suit la structure des modules partagés (`backend/modules/m07_local_catalogue/` avec `contract.py` , `router.py` , `service.py` , `mock.py` , `tool.py` , `tests/`), plus `agent.py` , `darija.py` , `events.py` , `pipeline/` et `evaluation/` , et le pipeline prévu par l'architecture : **parse** → **retrieve** → **filter** → **rerank**.

Entrée (`LocalShopInput`) — au moins un des champs `query` , `gap` , `category` / `subcategory` ou `image_embedding` :

Champ	Exemple	Utilisé par
`query`	« baskets blanches à Tunis pour 80 TND », « sbadri kahla »	Chat (BO8), écrans de recherche
`gap`	« white shirt »	Smart Buy (BO5), analyse de la garde-robe
`city`, `max_price_tnd`, `min_price_tnd`	« Tunis », 80	Filtres explicites
`category`, `subcategory`, `color`, `gender`	shoes, sneakers, white, women	Filtres explicites
`user_id`, `style_vector`	« usr_042 », « vec_u042 » (ou 512 nombres)	Profil de style (M5)
`image_embedding`	512 nombres	Photo d'une pièce (Vision M1 / Smart Buy)
`include_unavailable`, `k` (≤ 100), `offset`	false, 24, 24	Options et pagination

Sortie (`LocalShopOutput`) : la liste `results` reprend les champs prévus par l'architecture (`shop`, `area`, `item`, `price_tnd`, `match`), enrichis de l'identifiant, des liens, de la photo, des tailles, du genre, du stock et des **raisons**. S'y ajoutent `parsed` (filtres appliqués, requête traduite ou corrigée), `total_matches`, `note` et `search_id` (identifiant de la recherche dans le journal, §5.8).

5.2 Index FashionCLIP (base de connaissances)

FashionCLIP (`patrickjohncyh/fashion-clip`) est un réseau de neurones (architecture CLIP) entraîné par des chercheurs sur environ 800 000 photos de mode avec leur description. Il transforme **une photo en une liste de 512 nombres** (un « vecteur ») et **une phrase en anglais en une autre liste de 512 nombres**, de sorte qu'une photo et sa bonne description aient des vecteurs proches. Il est utilisé tel quel (*zero-shot*), sans réentraînement.

Pourquoi FashionCLIP : il comprend le **contenu visuel** même quand la description est pauvre ; l'architecture le recommande pour le module Vision, donc M7, M1 et M5 partagent le même espace ; il tourne **en local** sur CPU.

Le dossier `ml/data/shops/index/` contient trois fichiers :

Fichier	Contenu
`image_embeddings.npy`	Tableau de **6 375 × 512 nombres** (float32, 13 Mo), un vecteur normalisé par photo
`ids.json`	Le `product_id` de chaque ligne du tableau, dans le même ordre
`meta.json`	Modèle utilisé, dimension, nombre de produits, date et durée de construction

`pipeline/ingest.py` construit l'index de façon **incrémentale** : un produit déjà présent (même identifiant, donc même photo) est réutilisé. Pour la campagne 2, **4 129 nouvelles photos ont été encodées en 12 min 28 s** sur CPU, et les 2 465 anciennes réutilisées. Si le modèle change, `meta.json` empêche de mélanger des vecteurs de deux modèles (`--full` ré-encode tout).

5.3 Compréhension de la requête (`pipeline/parse.py` , `darija.py`)

La phrase de l'utilisatrice est transformée en critères :

```
« Je cherche une chemise en lin blanche moins de 100 dt à la Marsa »
  → subcategory: shirt · color: white · max_price_tnd: 100 · city: La Marsa (gouvernorat Tunis)
  → prompt FashionCLIP : « a photo of white linen shirt »
```

Il reconnaît les budgets (« moins de 80 dt », « entre 50 et 120 dinars », « 80 alf »), les villes tunisiennes, les couleurs, les catégories et des attributs (lin → linen, cuir → leather, soirée → evening…).

Darija. Beaucoup de demandes sont écrites en darija, en lettres latines avec des chiffres pour les sons arabes (« a7mar », « 5adhra », « 9ahwi ») ou en alphabet arabe (« صباط أحمر »). Un **lexique** d'environ 40 entrées (`darija.py`) remplace chaque mot darija par le mot français que les règles connaissent déjà, **avant** tout le reste : vêtements (*sabbat*, *sbadri*, *sorya*, *sarwel*, *kabbout*, *chkara*…), couleurs (*ahmar*, *kahla*, *bidha*, *azra9*, *dhahbi*…, avec leurs formes féminines en arabe comme ذهبية), genre (*rjel*, *nsa*, رجالي, نسائية), occasion (*3ers* = mariage) et budget (*a9al men* = moins de). L'article ou la préposition collés aux mots arabes sont gérés (« بالأسود »). Le champ `parsed.translated` montre comment la demande a été lue, et l'application l'affiche (« Darija comprise : « baskets noir moins de 150 alf » »). Seuls les mots au sens clair sont listés : « jupe » n'a pas d'entrée, ses graphies darija étant trop proches de « jebba ».

Genre. « homme », « femme », « women's », mais aussi « pour mon mari » ou « lel nsa » donnent le critère `gender` , et le prompt devient « a photo of men's white shirt ».

Fautes de frappe. Un mot inconnu mais très proche d'un mot connu est corrigé (« chemize » → « chemise »). Les **mots-clés des règles passent en priorité** : une boutique qui écrit elle-même une faute ne la rend pas « valide ». Un mot déjà compris (« noires », « dorée ») n'est jamais touché.

Pourquoi un analyseur à règles et non un LLM : il utilise **exactement les mêmes listes de mots** que le nettoyage, il est instantané, gratuit, déterministe et testable ; et il est mesuré (§6 : 100 % des 72 requêtes comprises).

Pourquoi un prompt en anglais : FashionCLIP n'a été entraîné que sur de l'anglais (§5.12). Les autres langues (français, darija, arabe) sont donc gérées par nos règles, pas par FashionCLIP.

5.4 Recherche hybride (`pipeline/retrieve.py`)

Deux scores sont calculés pour **chaque** produit : - **Visuel (FashionCLIP)** : similarité cosinus entre le prompt (ou la photo envoyée) et la photo du produit ; - **Texte (BM25)** : algorithme classique de recherche par mots sur le nom, la catégorie, la couleur, la boutique et la ville. Les mots de genre en sont retirés : un modèle « homme » reconnu d'après sa photo n'a pas forcément « homme » dans son nom.

Pourquoi hybride : le visuel trouve des pièces même mal décrites ; le texte capte les mots précis (un nom de boutique, « jebba ») que l'image ne contient pas. *Pourquoi un calcul exact :* avec ~6 400 produits, comparer à tous prend quelques millisecondes ; une base vectorielle n'est utile qu'à plus grande échelle.

5.5 Filtres (`pipeline/filter.py`)

Filtre	Type	Raison
Prix ≤ budget, prix ≥ minimum	Strict	Le budget en TND est une contrainte de l'utilisatrice
Ville **ou son gouvernorat**	Strict	« Tunis » inclut La Marsa ; une boutique sans adresse n'est pas mise dans une ville au hasard
Catégorie / sous-catégorie	Strict	Une demande de baskets ne doit pas renvoyer de sandales
Couleur	**Strict**	« robe noire » = seulement des robes noires ; les produits de couleur inconnue sont écartés
Genre	Strict pour l'autre genre	Une demande « homme » retire les pièces femme ; les pièces mixtes et de genre inconnu restent, classées plus bas
En stock	Strict (désactivable)	Ne pas proposer ce qu'on ne peut pas acheter

Pourquoi la couleur est devenue stricte. Dans la première version, la couleur n'était qu'un critère de score. Avec 7 robes noires en stock et 24 résultats affichés, « robe noire » montrait aussi des robes bleues, et une « Robe Nejma » d'UNJA (robe bleu marine de style jebba, sans couleur indiquée par la boutique). L'utilisatrice a demandé « seulement cette couleur ». L'évaluation (§6) a mesuré l'effet : les résultats faux dans le top 5 passent de **8,1 % à 1,1 %**.

Quand rien ne correspond, un critère est relâché à la fois, et `note` le dit : 1. d'abord la **ville** (« robe noire à Sousse » montre des robes noires d'autres villes, pas des robes bleues de Sousse) ; 2. puis le **stock** (articles en rupture, avec la mention « Rupture de stock ») ; 3. en dernier la **couleur**, seulement si elle n'existe nulle part (« Aucun article de couleur rouge parmi les baskets : voici les autres baskets disponibles. »).

Rien de compris (ni type, ni couleur, ni photo) : on ne garde que les produits qui contiennent les mots cherchés, sinon le moteur répond « Je n'ai trouvé aucun article correspondant à … ».

5.6 Score, style, diversité, pagination et explications (`pipeline/rerank.py`)

Le score `match` (entre 0 et 1) est une moyenne pondérée des éléments qui s'appliquent :

Composante	Poids	Mesure
Visuel	0,45	FashionCLIP requête ↔ photo, ramené sur 0–1
Texte	0,20	BM25, relatif au meilleur candidat
Attributs	0,20	Sous-catégorie, couleur et genre demandés (genre : identique ou mixte = 1, inconnu = 0,5)
Style	0,15	Vecteur de style de l'utilisatrice ↔ photo du produit

Les poids sont **renormalisés** selon les composantes disponibles.

Calibration. Les similarités FashionCLIP sont faibles en valeur absolue : texte → photo (médiane ≈ 0,11, 99e centile ≈ 0,30), d'où la plage [0,15 ; 0,33] ; photo → photo, plage [0,40 ; 0,85].

Diversité (MMR) et pagination. On évite de renvoyer 5 photos presque identiques (le même modèle en 5 coloris). Le MMR choisit les résultats un par un parmi les **2 000 meilleurs candidats**, un nombre fixe : ses n premiers choix ne dépendent donc pas de la taille de la page. La page 2 (`offset = 24`) prolonge exactement

la page 1, sans répéter ni oublier d'article. Vérifié sur « robe » : les 193 robes s'affichent toutes, chacune une seule fois, en moins de 120 ms par page.

Explications sans invention. Chaque résultat a des raisons construites uniquement à partir des données et des scores : « Baskets », « Couleur : blanc », « Modèle homme (estimé d'après la photo) », « 69.3 TND (budget 80 TND) », « Boutique à Tunis (près de La Marsa) », « Ressemble visuellement à la demande », « Marque tunisienne ». Elles alimentent l'écran BO6 et le module LLM (M8) sans qu'un modèle puisse inventer un fait.

5.7 Genre estimé d'après la photo (`pipeline/attributes.py`)

Les boutiques n'écrivent le genre que pour 1 834 produits sur 6 375. Pour les autres, FashionCLIP compare la photo à des phrases comme « women's shirt », « a man wearing a shirt »… (4 formulations par genre et par type de pièce, moyennées). La **marge** = 100 × (similarité « femme » − similarité « homme »). Le genre n'est retenu que si la marge dépasse **1,5** (`config.yaml`) ; sinon il reste inconnu.

Pourquoi un seuil : un faux « homme » cacherait une pièce à une recherche « femme », alors qu'un genre inconnu ne fait que la classer un peu plus bas.

Évaluation. Les produits dont le nom donne le genre servent de jeu de test : on compare la prédiction d'après la photo avec ce qui est écrit.

Marge minimale	Produits couverts	Prédictions justes
0	100 %	93,3 %
1	92,2 %	95,6 %
1,5 (retenue)	**88,5 %**	**96,7 %**
3	72,8 %	98,8 %

Mesuré sur 1 828 produits (`ml/data/shops/attributes_report.md`). Les prédictions sont cohérentes boutique par boutique : Exist, marque homme, sort à 266 « homme » sur 267.

Couleur d'après la photo : essayée, non retenue. La même méthode ne retrouve la couleur écrite que dans **47 % des cas** (57 % en regroupant les nuances proches comme bleu et marine) : trop peu fiable pour remplir les 15 % de couleurs manquantes. Cela reste une piste (§8).

5.8 Journal des recherches et des clics (`events.py`)

Chaque vraie recherche (API ou assistant, pas le mock) et chaque clic sont ajoutés à `ml/data/logs/m07_events.jsonl` (hors git). Une ligne par événement, avec les champs du schéma `Event` partagé du projet (`event_id` , `user_id` , `type` , `target_id` , `value` , `channel` , `ts`) et un objet `data` : - `local_search` : la demande, les filtres, ce qui a été compris, le nombre de résultats, les produits affichés (boutique, `match` , prix), la note et la latence ; - `product_view` (fiche ouverte) et `shop_click` (« Voir sur le site de la boutique ») : produit, boutique, `search_id` et rang, envoyés par l'application via `POST /m07/events` .

Aucune adresse IP ni donnée d'appareil n'est gardée ; `user_id` seulement s'il est fourni. `python -m modules.m07_local_catalogue.events` en fait le résumé : volume, part de darija, demandes sans résultat (la **demande non satisfaite**), et impressions, vues et clics par boutique. C'est la donnée de départ du **tableau de bord des boutiques** du module M14.

5.9 Intégration dans le projet

- **Outil de l'orchestrateur** : `tool.py` expose l'agent sous le nom `localshop` (découvert automatiquement) ; ses recherches sont journalisées avec `channel = orchestrator`.
- **API REST** (`router.py` , préfixe `/m07`) :
- `POST /m07/search` : recherche (avec `k` et `offset` pour paginer) ;
- `POST /m07/events` : clics de l'application ;
- `GET /m07/shops` : liste des boutiques ;
- `GET /m07/products/{product_id}` : fiche d'un produit ;
- `GET /m07/images/{nom}` : photo locale d'un produit.
- **Sans les données** sur la machine, le service répond avec `mock.py` au lieu d'échouer.
- **Écran BO6** (`mobile/lib/features/bo6_local_market/`) : recherche, filtres ville et budget, critères compris (dont darija et genre), grille de photos avec « Voir 24 de plus » et « Tout afficher », fiche produit avec « Voir sur le site de la boutique » (ouvre la page) et « Copier le lien ».
- Le modèle est chargé à la première recherche (environ 12 s), puis **chaque recherche prend environ 40 ms** (médiane 37 ms, 95e centile 42 ms).

5.10 Exemples de résultats réels

Requête	Résultat
« robe noire »	27 robes noires de 12 boutiques (Ms. Marion, Maison ARA, Hraier…) ; 7 avant la campagne 2
« jebba »	73 tenues traditionnelles (Hraier en tête : jebba moderne 120 TND) ; 13 avant
« maillot de bain »	29 maillots (Lyséa · Tunis en tête) ; 5 avant
« collier doré »	90 colliers dorés (Gaya en tête, 29,9 – 34,9 TND)
« bracelet »	56 bracelets (Iley'com, Strass, Hraier)
« costume »	26 costumes (Exist, GET)
« sandales à Sfax »	245 sandales (SeaSide, Carolie, Baletto · Sfax)
« escarpins rouges »	2 escarpins rouges (SeaSide · Sfax)

5.11 Corrections après les tests dans l'application

Premier retour (14/10) :

Recherche	Avant	Cause	Après
« costume »	Costumes puis bracelets, casquettes, pulls	Mot inconnu + liste toujours remplie	Costumes seulement
« colier » (faute)	Liste au hasard	Pas de tolérance aux fautes	Colliers
« bracelet »	1 bracelet + 4 bagues	Tous les bijoux dans une seule catégorie	Bracelets seulement
« robe blanche » + Sousse	« MAGIC · Tunis » affiché	La carte montrait la première ville de la chaîne	`area` = ville qui correspond au filtre

Deuxième retour (15–16/10) :

Recherche ou problème	Avant	Cause	Après
« chemise homme blanche »	Des « Chemise Femme » dans le top 5	Genre ignoré	5 chemises homme sur 5 (genre lu dans le nom, sinon estimé d'après la photo)
« sabbat ahmar », « سروال رجالي »	0 résultat	Darija et arabe non compris	Lexique darija : chaussures rouges, pantalons homme
« robe noire »	Robes bleues et une jebba bleue parmi les 24	Couleur seulement dans le score	Couleur stricte : uniquement des robes noires
« bague argentée », « leather handbag », « سنسلة ذهبية »	Couleur ou type manqués	Formes féminines et mots anglais absents	Trouvés par le jeu de test (§6), règles corrigées
195 robes, 24 affichées	Pas moyen de voir les autres	Pas de pagination	`offset` + boutons « Voir 24 de plus » / « Tout afficher »
Lien de la boutique	Copié seulement	Pas d'ouverture d'URL dans l'app	« Voir sur le site de la boutique » ouvre la page
App lente (≈ 2 s par appel)	Serveur de l'app vers `localhost`	Windows essaie d'abord IPv6	Serveur de l'app vers `127.0.0.1` : 20 à 60 ms

5.12 FashionCLIP est-il le meilleur choix ?

Comparaison sur notre catalogue (campagne 1). Trois modèles de mode ont été évalués sur 1 873 photos, avec les étiquettes des boutiques comme référence (105 recherches « couleur + type ») :

Mesure	FashionCLIP (retenu)	Marqo-FashionSigLIP	Marqo-FashionCLIP
Recherche « couleur + type » : bons résultats dans le top 10	29,7 %	**32,5 %**	30,9 %
Recherche par type : bons résultats dans le top 10	67,6 %	68,9 %	**69,4 %**
Type reconnu sur la photo	66,8 %	**72,0 %**	67,3 %
Couleur reconnue sur la photo	47,9 %	47,5 %	**48,9 %**
Vitesse sur CPU	**96 ms/photo**	234 ms/photo	236 ms/photo
Taille du vecteur	**512**	768	**512**

Décision : garder FashionCLIP pour l'instant. Les modèles récents gagnent 1 à 3 points (proche du bruit de mesure) ; FashionCLIP est 2,4 fois plus rapide et respecte la convention de 512 du projet. Marqo-FashionSigLIP (768) imposerait de changer aussi M1 et M5 : c'est une décision d'équipe.

Langues. FashionCLIP ne comprend vraiment que l'anglais (77 % de bons types dans le top 10 en anglais contre 58 % en français sur 12 recherches directes). C'est pourquoi le français, la darija et l'arabe passent par nos règles. L'évaluation du §6 le confirme à plus grande échelle : FashionCLIP seul sur la requête brute obtient 0,03 de nDCG sur la darija, contre 0,97 pour le pipeline.

5.13 Le LLM de l'agent : Qwen 2.5 7B, en local

Depuis le 22/10, l'agent `localshop` (M7 et sa compétence M14) a **un LLM : Qwen 2.5 7B**, exécuté sur la machine avec **Ollama** (`llm.py`). Pourquoi ce modèle : il est gratuit et local (pas de clé d'API, les requêtes des clients ne sortent pas de la machine), il tient en mémoire sur un PC de 32 Go sans carte graphique, et il est bon en français et en arabe, ce qui compte pour la darija.

Rôle dans M7 : comprendre les requêtes que les règles ne comprennent pas. Les règles du §5.3 restent la première étape, rapides et exactes. Le LLM n'est appelé que lorsqu'elles ne trouvent **ni type de pièce, ni couleur, ni photo** (`pipeline/understand.py`) :

```
"haja nlabesha l b7ar fi sif"  ──►  règles : rien compris
        │
        ▼  Qwen 2.5 7B, sortie JSON imposée par un schéma (Ollama structured outputs)
{french: "…", subcategory: <code du catalogue>, color: <code>, gender, max_price_tnd, city}
        │
        ▼  vérifications du code
budget écrit dans la requête ? ville et genre dits dans la requête ? sinon supprimés
        │
        ▼  la recherche normale (FashionCLIP + BM25 + filtres) tourne sur ces filtres
gardé seulement si elle trouve des pièces ; note : « Demande comprise avec l'IA (qwen2.5:7b) : … »
```

Le LLM **ne voit pas les produits et ne choisit rien** : il traduit la demande en filtres, avec un vocabulaire imposé (les codes du catalogue). S'il est éteint, lent ou faux, la réponse est celle des règles, comme avant. Les tests utilisent un faux LLM ; ils n'appellent jamais Ollama.

Deux leçons de la mise au point, mesurées sur les requêtes du §6.6 : - avec des exemples dans le prompt, le petit modèle les **recopiait** dans des réponses sans rapport (« tenue de plage » pour une tenue de travail) : le prompt n'a plus d'exemples, mais demande « la pièce la plus probable » selon l'usage (plage → maillot, hiver → manteau, entretien → costume) ; - le modèle **inventait un genre** (« women ») : un genre n'est gardé que si la requête le dit.

---

6. Évaluation

6.1 Jeu de test

`evaluation/queries.yaml` contient **72 requêtes** écrites comme les utilisatrices les tapent : 28 en français, 12 en anglais, 18 en darija (lettres latines) et 14 en alphabet arabe, avec des fautes, des budgets, des villes, des couleurs, des genres et des matières. Pour chacune, **l'intention est écrite à la main** : type, couleur, genre, budget, ville, et éventuellement des mots de matière ou d'occasion attendus dans le nom (« cuir », « soirée »). Exemple :

```
- {id: dj01, lang: darija, query: "sbadri kahla a9al men 150 alf",
   expect: {type: sneakers, color: black, max_price: 150}}
```

Une commande produit le rapport `evaluation/RESULTS.md` :

```
python -m modules.m07_local_catalogue.evaluation.run
```

6.2 Deux niveaux de mesure

Niveau	Référence	Mesures
Compréhension	Intention écrite à la main (*gold*)	Part des requêtes dont chaque champ (type, couleur, genre, budget, ville) est bien lu ; « exact » = tous les champs justes
Classement	Note de chaque produit calculée à partir de l'intention et de ses attributs (*silver*) : 2 = bon type et tous les critères, 1 = bon type mais un critère manquant ou inconnu, 0 = mauvais type, hors budget, autre genre ou autre couleur	nDCG@10, P@5 (notes 2 dans les 5 premiers), MRR, résultats faux dans le top 5, requêtes sans résultat, latence

6.3 Résultats (catalogue du 16/10, 6 375 produits)

Compréhension : 100 % des 72 requêtes sont lues exactement (tous les champs justes), dans les quatre langues. Sans le lexique darija : 56,9 % (0 % en darija, 7,1 % en arabe).

Classement — comparaison des variantes (ablation) :

Variante	nDCG@10	P@5	MRR	Faux dans le top 5	Sans résultat
BM25 seul, requête brute	0,329	27,2 %	0,331	41,4 %	38,9 %
FashionCLIP seul, requête brute	0,281	23,1 %	0,346	66,7 %	0 %
Pipeline sans FashionCLIP	0,935	84,2 %	0,928	0,8 %	0 %
Pipeline, score visuel seul	0,917	82,5 %	0,903	1,1 %	0 %
Pipeline sans lexique darija	0,521	43,6 %	0,507	6,0 %	40,3 %
Pipeline sans genre	0,832	74,4 %	0,845	12,8 %	0 %
Pipeline, couleur souple (avant)	0,906	82,2 %	0,912	8,1 %	0 %
Pipeline complet	**0,934**	**84,4 %**	**0,938**	**1,1 %**	**0 %**

Par langue (nDCG@10) : français 0,908, anglais 0,905, darija 0,974, arabe 0,962. Latence : médiane 37 ms, 95e centile 42 ms.

6.4 Ce que ces chiffres montrent

- **Comprendre la demande est l'essentiel.** Une recherche par mots (BM25) ou FashionCLIP seuls sur la phrase brute plafonnent à 0,33 de nDCG ; le pipeline atteint 0,93.
- **Le lexique darija est indispensable** : sans lui, le nDCG tombe à 0,52 et 40 % des requêtes ne donnent rien.
- **Le genre et la couleur stricte éliminent les erreurs visibles** : sans genre, 12,8 % de faux dans le top 5 ; avec la couleur souple, 8,1 % ; pipeline complet : 1,1 %.

- **Le jeu de test a trouvé de vrais défauts.** Au premier passage, 4 requêtes étaient mal comprises (« argentée », « handbag », نسائية, ذهبية), puis « colier dorée » après l'ajout d'une boutique qui écrit elle-même « colier ». Les règles ont été corrigées, et un test protège chaque cas.

6.5 Limites de l'évaluation

- **Les notes *silver* utilisent les mêmes attributs que les filtres** (type, prix, couleur, genre, ville). Elles favorisent donc le pipeline sur ces critères ; elles montrent surtout l'apport de la compréhension par rapport aux méthodes brutes, et le classement de ce qui passe les filtres.
- **Elles ne regardent pas les photos.** C'est pourquoi « sans FashionCLIP » obtient un score presque identique au pipeline complet (0,935 contre 0,934) : l'apport visuel (ressemblance, style) n'est pas mesurable avec ces notes. Seules des **notes humaines** peuvent trancher.
- **Le 100 % de compréhension est optimiste** : les défauts trouvés par le jeu de test ont été corrigés sur ce même jeu. Des requêtes écrites par d'autres personnes donneraient un chiffre non biaisé.
- 63 % des genres sont estimés d'après la photo (96,7 % justes, §5.7).

Notes humaines. `ml/data/shops/eval/judgments_todo.csv` liste les 1 533 produits affichés par le pipeline et les deux méthodes brutes (top 10 de chacune). Il suffit de noter une vingtaine de requêtes (`human_rel` = 0, 1 ou 2, en regardant la photo et le lien), d'enregistrer le fichier sous `judgments.csv` et de relancer : `RESULTS.md` ajoute alors le nDCG@10 et le P@5 humains, et l'accord avec les notes automatiques (kappa de Cohen).

6.6 Ce que le LLM apporte : 16 requêtes difficiles

Sur les 72 requêtes du §6.1, les règles comprennent déjà tout : le LLM n'y est jamais appelé. Pour le mesurer, nous avons écrit **16 requêtes que les règles ne comprennent pas** (français, anglais, darija, arabe : « haja nlabesha l b7ar fi sif », « an outfit for a job interview », « عندي عرس في سوسة نحب حاجة باهية »…), avec l'intention notée à la main (`evaluation/queries_llm.yaml` , script `llm_eval.py`).

	Type compris et juste	Budget / ville justes	Pièces trouvées	Temps médian (CPU)
Règles seules	0/16	15/16	0/16	–
Règles + Qwen 2.5 7B	**11/16**	16/16	14/16	14,8 s
Règles + Qwen 2.5 3B	12/16	16/16	16/16	7,6 s

- Le LLM fait passer ces requêtes de **0 à 11 sur 16** bien comprises ; aucun budget ni aucune ville n'est inventé (16/16).
- **7B et 3B font jeu égal** sur ce petit jeu (11 contre 12 : pas une vraie différence). Le 7B reformule mieux (« costume d'affaires » pour un entretien, « sac de femme » pour un cadeau à une mère, là où le 3B écrit « robe de travail » et « robe de fête »), mais il est **deux fois plus lent** sur processeur. Le modèle se change dans `config.yaml → llm.model` .
- Les échecs du 7B : la plage comprise comme « chemise », des chaussures pour l'hiver comprises comme « chemise », une tenue chaude comprise comme « robe de soirée », le hammam non compris.
- **Limite** : ces 16 requêtes et leur intention ont été écrites par la même équipe que le système ; un jeu écrit par d'autres personnes donnerait un chiffre plus juste. Le temps de réponse (≈ 15 s) vient de l'absence de carte graphique ; c'est pourquoi le LLM n'est appelé qu'en dernier recours.

---

7. Comment tester le module

Les commandes backend se lancent depuis `backend/`, celles de l'application depuis `mobile/`.

7.1 Tests automatiques (sans modèle ni internet)

```
cd backend
pip install -r requirements-dev.txt
pytest modules/m07_local_catalogue -q     # résultat attendu : 128 passed
pytest -q                                 # tout le backend : 153 passed
cd ../mobile && flutter test              # écran BO6 : 5 tests
```

Ces tests utilisent un mini-catalogue et un faux encodeur : ils n'ont besoin ni de `torch`, ni du modèle, ni des données.

Fichier	Ce qui est vérifié
`test_search.py`	Exemple « baskets blanches à Tunis 80 TND », gouvernorat, couleur stricte et ordre des assouplissements, pagination sans répétition, fautes de frappe, bijoux et costumes, mots inconnus, articles en rupture
`test_darija_gender.py`	Darija en lettres latines et en arabe, budget en « alf », genre dans la requête et dans le nom, filtre et raisons de genre, genre d'après la photo
`test_evaluation.py`	Notes de pertinence, nDCG / P@5 / MRR, compréhension par champ, exécution complète sur un mini-catalogue
`test_events.py`	Journal des recherches et des clics, `search_id`, route `/m07/events`, résumé pour M14
`test_router.py`	Routes `/m07/*`, repli sur le mock sans données, photos protégées, vecteur de style demandé à M5
`test_scraper_normalize.py`	Catégories (FR/EN/tunisien/arabe), apostrophes typographiques, « haut de gamme », hors mode à deux niveaux, marques étrangères
`test_clean.py`, `test_ingest.py`, `test_contract.py`, `test_mock.py`	Nettoyage, index incrémental, contrat, mock
`mobile/test/bo6_local_market_test.dart`	Écran BO6 : recherche, critères compris, prix en TND, bouton « Voir plus »

7.2 Prérequis pour une recherche réelle

```
pip install -r modules/m07_local_catalogue/requirements.txt   # torch, transformers...
```

Les données sont dans `ml/data/shops/` (récupérées avec `git pull`). Pour les reconstruire :

```
python -m modules.m07_local_catalogue.scraper.run          # 1. scraping, photos (~1 h)
python -m modules.m07_local_catalogue.scraper.clean        # 2. nettoyage, URL (~55 min)
python -m modules.m07_local_catalogue.pipeline.ingest      # 3. index (incrémental)
python -m modules.m07_local_catalogue.pipeline.attributes  # 4. genre d'après la photo
python -m modules.m07_local_catalogue.evaluation.run       # 5. évaluation (~3 min)
```

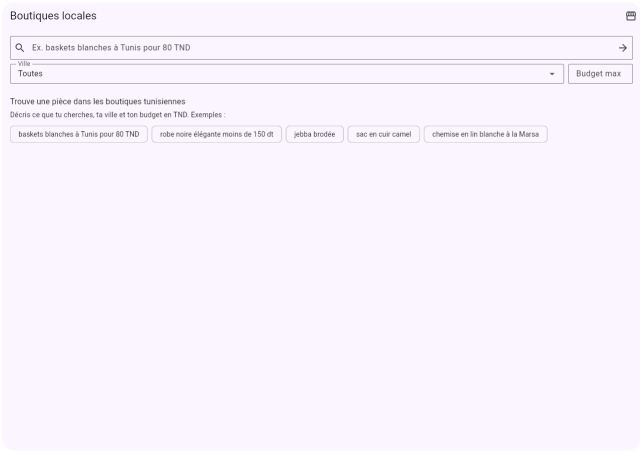
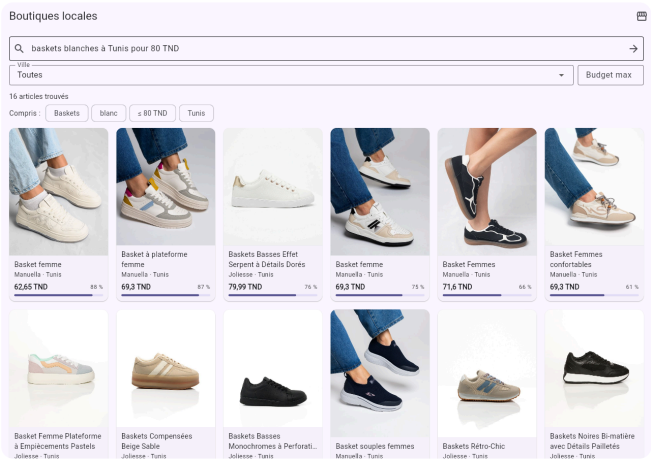
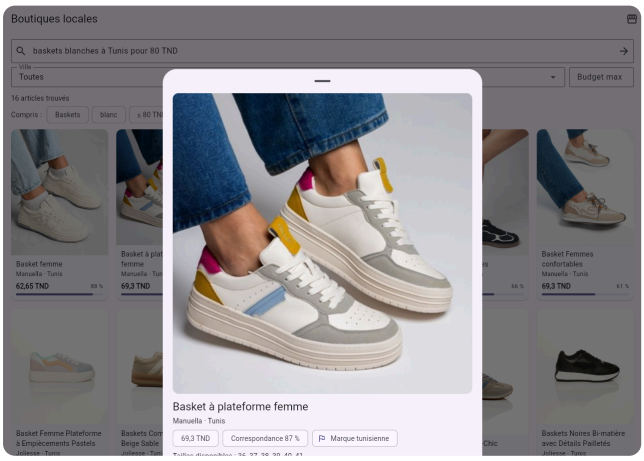
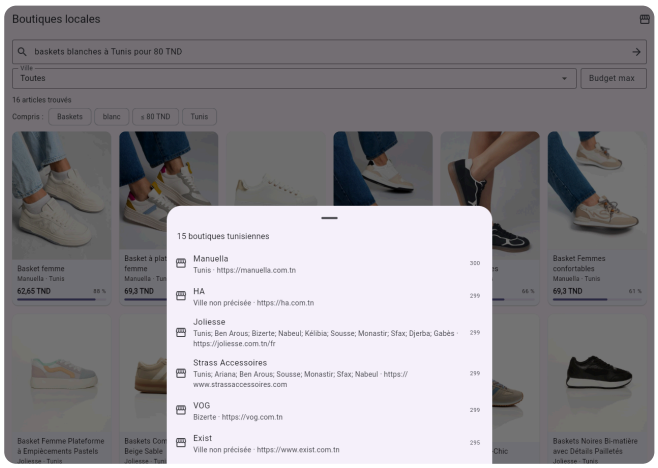
7.3 Tester par l'API (Swagger)

```
cd backend
uvicorn api.main:app --host 127.0.0.1 --port 8010
```

Ouvrir **http://127.0.0.1:8010/docs**, choisir `POST /m07/search`, **Try it out**, coller un corps JSON (voir le tableau du §7.4), **Execute**.

7.4 Tester dans l'application (front Flutter)

L'écran BO6 « Boutiques locales » (`mobile/lib/features/bo6_local_market/`) appelle M7 par l'API, comme le fera l'application finale.

Accueil	Résultats
	
Fiche produit	**Boutiques**
	

Captures de la première version de l'écran (14/10).

1. **Lancer l'API** (terminal 1) : `cd backend` puis `uvicorn api.main:app --host 127.0.0.1 --port 8010`
2. **Construire l'application web** (une fois, puis après chaque modification du code Dart) : `powershell cd mobile flutter pub get flutter build web --dart-define=API_URL=http://localhost:8090`
3. **Servir l'application et l'API à la même adresse** (terminal 2) : `python tool/serve_app.py`. *Pourquoi :* le navigateur bloque les appels vers un autre port (règle CORS). `serve_app.py` sert l'application et transmet les appels `/m07/...` à l'API : n'importe quel navigateur fonctionne, sans drapeau spécial.
4. Ouvrir **http://localhost:8090/#/bo6_local_market**. Sur un téléphone : `flutter run --dart-define=API_URL=http://<IP-du-PC>:8010` (l'API lancée avec `--host 0.0.0.0`).

Action	Résultat attendu
« baskets blanches à Tunis pour 80 TND »	1 basket blanche (Manuella) ; « Compris : Baskets · Blanc · ≤ 80 TND · Tunis »
« robe noire »	27 robes, **toutes noires**
« robe »	193 articles, 24 affichés, puis « Voir 24 de plus » et « Tout afficher (169 restants) »
« sbadri kahla a9al men 150 alf »	« Darija comprise : « baskets noir moins de 150 alf » », 47 baskets noires ≤ 150 TND
« chemise homme blanche »	Pastille « Homme », chemises homme blanches (Cravate)
« chemize » (avec la faute)	« Recherche corrigée : « chemise » »
Toucher un article	Photo, prix, correspondance, tailles, raisons (dont « Modèle homme (estimé d'après la photo) »), boutons « Voir sur le site de la boutique » et « Copier le lien »
Icône boutique (en haut à droite)	Les 43 boutiques avec leurs villes et leur site
`{"city": "Tunis"}` (API)	Erreur **422** (rien à chercher)

L'application démarre sur l'écran BO2 (squelette partagé, `mobile/lib/app/router.dart`) : il faut ouvrir l'adresse avec `#/bo6_local_market`.

7.5 Tester directement en Python

```
import asyncio
from modules.m07_local_catalogue.agent import LocalShopAgent

agent = LocalShopAgent()
out = asyncio.run(agent({"query": "sbadri kahla a9al men 150 alf", "k": 5}))
print(out["parsed"])              # critères compris, dont "translated"
for r in out["results"]:
    print(r["match"], r["shop"], r["area"], r["item"], r["price_tnd"], r["reasons"])
```

7.6 Vérifier les données

- Ouvrir `ml/data/shops/local_catalogue_clean.csv` dans Excel (encodage UTF-8).

- Lire `cleaning_report.md` (nettoyage) et `attributes_report.md` (genre d'après la photo).
- Filtrer la colonne `quality_flags` pour voir les prix à contrôler.

---

8. Limites et pistes d'amélioration

Limite	Piste
57 % des produits sans ville (boutiques en ligne sans adresse)	Contacter les boutiques ; notion de « livraison partout »
Les produits sans couleur sont exclus d'une recherche par couleur (ex. une robe noire de MAGIC)	Couleur d'après la photo plus fiable : couleur dominante du vêtement détouré (M1), mesurée avec le jeu de test
Occasion et matière seulement lues dans le texte (« robe de soirée » renvoie aussi des robes de jour)	Attributs zero-shot « soirée », « cuir », « lin »… sur les photos, évalués
Prix aberrants signalés mais gardés (sacs Hraier à 14 900 TND)	Revue manuelle des `price_very_high`
Boutiques non couvertes : ZEN et Souk El Kahina (robots.txt), Mabrouk et HKEYA (refus techniques), Kastelo, Barsha…	Demander un fichier partenaire (CSV) ou l'accord des boutiques, comme le prévoit l'architecture ; analyseurs HTML dédiés
Lingerie très représentée (606 produits, 4 boutiques)	Plafond par catégorie lors de l'équilibrage
Évaluation du classement sans notes humaines ; compréhension mesurée sur le jeu qui a servi à corriger	Remplir `judgments.csv` ; 50 requêtes écrites par d'autres personnes
Poids du score fixés à la main	Les apprendre sur les notes humaines puis sur les clics du journal (*learning to rank*)
Mots absents du lexique non compris (le moteur le dit)	Signal texte multilingue (bge-m3, e5) sur les noms de produits ; LLM de M8 pour les phrases inhabituelles
Photos dans git (≈ 330 Mo)	Passer `ml/data/shops/images/` sous DVC ou Git LFS si le dépôt devient trop lourd
Données figées entre deux scrapings	Relance planifiée (M4) avec `--merge` ; cache des URL de 7 jours

---

9. Annexe : fichiers du module

```
backend/modules/m07_local_catalogue/
├── agent.py            agent M7 : parse → retrieve → filter → rerank, assouplissements, pagination
├── contract.py         entrée / sortie (Pydantic), ClickEvent
├── darija.py           lexique darija (lettres latines et arabe) → français
├── events.py           journal des recherches et des clics + résumé pour M14
├── taxonomy.py         vocabulaire : catégories, bijoux, couleurs, genres, villes, gouvernorats
├── config.yaml         modèle, poids, calibration, seuil du genre, journal, emplacement des données
├── paths.py, clients.py, router.py, service.py, mock.py, tool.py
├── pipeline/
│   ├── parse.py        compréhension (darija, genre, fautes de frappe) + prompt anglais
│   ├── retrieve.py     FashionCLIP + BM25
│   ├── filter.py       prix, ville, catégorie, couleur, genre, stock
│   ├── rerank.py       score, style, diversité (MMR), raisons
│   ├── encoder.py      FashionCLIP en local
│   ├── catalogue.py    chargement de la base + index + vocabulaire
│   ├── ingest.py       construction incrémentale de l'index (hors ligne)
│   └── attributes.py   genre d'après la photo + évaluation (hors ligne)
├── scraper/
│   ├── shops.py        43 boutiques retenues, boutiques écartées (avec raisons)
│   ├── sources.py      un adaptateur par plateforme
│   ├── client.py       client HTTP respectueux (robots.txt, délais, sans cookies)
│   ├── normalize.py    catégories, couleurs, tailles, marques, hors mode, enfants
│   ├── images.py       téléchargement des photos
│   ├── run.py          lancement du scraping (--shops, --merge, --delay)
│   └── clean.py        nettoyage + vérification des URL (cache 7 jours)
├── evaluation/
│   ├── queries.yaml    72 requêtes avec leur intention écrite à la main
│   ├── run.py          compréhension, classement, ablation, notes humaines
│   └── RESULTS.md      résultats générés
└── tests/              128 tests
ml/data/shops/          données du module (dans git, branche BO6/local_catalogue)
├── local_catalogue.csv / .xlsx   données brutes du scraping (6 760 produits)
├── local_catalogue_clean.csv     base de connaissances nettoyée (6 375 produits)
├── cleaning_report.md, attributes_report.md
├── images/ (6 760 photos)  index/ (FashionCLIP)  url_checks.json
└── eval/judgments_todo.csv       produits à noter à la main
ml/data/logs/m07_events.jsonl     journal des recherches (hors git)
mobile/lib/features/bo6_local_market/   écran BO6 « Boutiques locales » (Flutter)
mobile/test/bo6_local_market_test.dart  tests de l'écran (5)
mobile/tool/serve_app.py                application web + API à la même adresse
rapport/build_pdf.py                    génération des PDF de ce rapport
```